

Целта на този документ е с помощта на няколко задачи и примера да изясни основните идеи за построяването на минимален суфиксен автомат по дадена дума, [BBH<sup>+</sup>85].

Основните понятия, които използваме са:

**Дефиниция 0.1** (Релация на Майхил – Нероуд). За език  $L \subseteq \Sigma^*$  и думи  $u, v \in \Sigma^*$ :

$$u \equiv_L v \stackrel{def}{\iff} \forall \gamma \in \Sigma^* (u \circ \gamma \in L \leftrightarrow v \circ \gamma \in L).$$

**Дефиниция 0.2.** За дума  $w \in \Sigma^*$  с  $\text{Pref}(w)$ ,  $\text{Inf}(w)$  и  $\text{Suff}(w)$  бележим съответно множествата от всички префикси, всички инфикси и всички суфикси на думата  $w$ .

**Дефиниция 0.3** (*end-pos<sub>w</sub>*). За дума  $w = a_1 a_2 \dots a_n$ ,  $a_i \in \Sigma$ , и дума  $u \in \Sigma^*$ :

$$\text{end-pos}_w(u) = \{i \mid 0 \leq i \leq n \text{ \& } u = a_{i-|u|+1} \dots a_i\}.$$

**Дефиниция 0.4** ((каноничен) представител). Ако  $w \in \Sigma^*$  и  $v \in \text{Inf}(w)$ , то  $\frac{w}{v}$  е най-дългата дума в класа на еквивалентност  $[v]_{\equiv_{\text{Suff}(w)}}$ .

**Дефиниция 0.5** (*slink*). Ако  $w \in \Sigma^*$  и  $v \in \Sigma^+$ , то  $s = \text{slink}_w(v)$  е най-дългият суфикс на  $v$ , за който  $v \not\equiv_{\text{Suff}(w)} s$ .

По дадена дума  $w \in \Sigma^*$  искаме да намерим:

$$\begin{aligned} Q_w &= \left\{ \frac{w}{v} \mid v \in \text{Inf}(w) \right\} \\ \text{за всяко } v \in Q_w : & \quad \text{slink}_w(v) \\ \text{за всяко } v \in Q_w : & \quad \delta_w(v, a) = \begin{cases} \frac{w}{va}, & \text{ако } va \in \text{Inf}(w) \\ \neg!, & \text{иначе,} \end{cases} \end{aligned}$$

където  $a \in \Sigma$ .

## 1 Връзки между *end-pos<sub>w</sub>*(.) и $\equiv_{\text{Suff}(w)}$

**Задача 1.1.** Нека  $w = \text{bbacbbba}$ . Нека  $L = \text{Suff}(w)$  е езикът от суфикси на думата  $w$ .

1. Определете *end-pos<sub>w</sub>*(*a*), *end-pos<sub>w</sub>*(*ba*) и *end-pos<sub>w</sub>*(*bba*).
2. Намерете елементите на класа на еквивалентност  $[a]_{\equiv_L}$ .
3. Намерете *end-pos<sub>w</sub>*(*c*), *end-pos<sub>w</sub>*(*aa*) и *end-pos<sub>w</sub>*(*baa*).

**Задача 1.2.** Докажете отново, че за всяка дума  $w \in \Sigma^*$  и думи  $u, v \in \Sigma^*$  следните са еквивалентни:

1.  $u \equiv_L v$ ,
2. *end-pos<sub>w</sub>*(*u*) = *end-pos<sub>w</sub>*(*v*).

**Задача 1.3.** Нека  $w = \text{bbacbbba}$  и  $w' = w \circ a$ .

1. Определете  $\text{end-pos}_{w'}(a)$ ,  $\text{end-pos}_{w'}(ba)$ ,  $\text{end-pos}_{w'}(bba)$ ,  $\text{end-pos}_{w'}(aa)$ ,  $\text{end-pos}_{w'}(baa)$ ,  $\text{end-pos}_{w'}(w')$  и сравнете получените резултати с тези от [задача 1](#).
2. Сравнете  $\text{end-pos}_w(bb)$  и  $\text{end-pos}_{w'}(bb)$ .

**Задача 1.4.** Нека  $w \in \Sigma^*$ ,  $a \in \Sigma$  и  $w' = w \circ a$  са произволни. Докажете, че:

1.  $\text{Inf}(w') \setminus \text{Inf}(w) \subseteq \text{Suff}(w')$ .
2. ако  $v \in \text{Suff}(w')$ , то:  $\text{end-pos}_{w'}(v) = \text{end-pos}_w(v) \cup \{|w'|\}$ .
3. ако  $v \notin \text{Suff}(w')$ , то:  $\text{end-pos}_{w'}(v) = \text{end-pos}_w(v)$ .

## 2 Свойства на $\text{slink}_w$

**Задача 2.1.** Нека  $w = bbacbbba$  и  $w' = w \circ a$ . Намерете:

1.  $\text{slink}_w(w)$ ,  $\text{slink}_w(bba)$ ,  $\text{slink}_{w'}(a)$ ,  $\text{slink}_w(bbac)$ ,  $\text{slink}_w(bb)$ ,  $\text{slink}_w(b)$ .
2.  $\text{slink}_{w'}(w)$ ,  $\text{slink}_{w'}(w')$ ,  $\text{slink}_{w'}(bba)$ ,  $\text{slink}_{w'}(a)$ .

**Задача 2.2.** Нека  $w \in \Sigma^*$ ,  $a \in \Sigma$  и  $w' = w \circ a$ . Докажете, че ако  $u, v \in \text{Inf}(w')$  са такива, че:

$$u \equiv_{\text{Suff}(w)} v \ \& \ u \not\equiv_{\text{Suff}(w')} v,$$

то поне една от двете думи  $u$  и  $v$  е еквивалентна на  $w'$  или  $\text{slink}_{w'}(w')$  относно  $\equiv_{\text{Suff}(w')}$ .  
Заключете, че:

$$\text{ind}(\equiv_{\text{Suff}(w)}) + 1 \leq \text{ind}(\equiv_{\text{Suff}(w')}) \leq \text{ind}(\equiv_{\text{Suff}(w)}) + 2.$$

**Задача 2.3.** За думите  $w = bbacbbba$  и  $w' = w \circ a$  намерете  $Q_w$  и  $Q_{w'}$ .

**Задача 2.4.** Докажете, че за всеки  $w \in \Sigma^*$ ,  $a \in \Sigma$  и  $w' = w \circ a$  е в сила:

$$Q_{w'} = Q_w \cup \{w', \text{slink}_{w'}(w')\}.$$

## 3 Пресмятане на $\text{slink}_{wa}(wa)$

**Задача 3.1.** Нека  $w = bbacbbba$  и  $w' = w \circ a$  намерете:

1. всички  $v \in Q_w$ , за които  $v \circ a \in \text{Inf}(w)$ .
2. всички  $v \in \text{Suff}(w)$ , за които  $v \circ a \in \text{Inf}(w)$ .
3. всички  $v \in \text{Suff}(w) \in Q_w$ , за които  $v \circ a \in \text{Inf}(w)$ .

<b>FindStem</b> ( $Q, \text{slink}, \delta, w, w', a$ )	<b>NewSlink</b> ( $Q, \text{slink}, \delta, u, w', a$ )
@1 $u \leftarrow w$	@1 $v \leftarrow \delta(u, a), s \leftarrow u \circ a$
@2 <b>while</b> $u \neq \text{NULL}$ <b>and</b> $\neg \delta(u, a)$	@2 $Q \leftarrow Q \cup \{s\}$
@3 $\delta(u, a) \leftarrow w'$	@3 $\text{slink}(s) \leftarrow \text{slink}(v)$
@4 $u \leftarrow \text{slink}(u)$	@4 $\text{slink}(v) \leftarrow s$
@5 <b>done</b>	@5 $\text{slink}(w') \leftarrow s$
@6 <b>return</b> $u$	@6 <b>for</b> $b \in \Sigma$ : $\delta(v, b) \neq \text{NULL}$ <b>do</b>
	@7 $\delta(s, b) \leftarrow \delta(v, b)$
	@8 <b>return</b> $s$

**Задача 3.2.** Нека  $w \in \Sigma^*$ ,  $a \in \Sigma$  и  $w' = w \circ a$ . Да разгледаме процедурата **FindStem**<sup>1</sup>, в която предполагаме, че  $Q = Q_w \cup \{w'\}$ ,  $\text{slink} = \text{slink}_w$  и  $\delta = \delta_w$ . Нека  $u$  е резултатът от изпълнението на **FindStem**.

Докажете, че:

1.  $\text{slink}_{w'}(w') = \begin{cases} \varepsilon & \text{ако } u = \text{NULL} \\ u \circ a & \text{иначе.} \end{cases}$
2. ако  $u \neq \text{NULL}$  и  $u \circ a \neq \delta_w(u, a)$ , то  $|\delta_w(u, a)| > |u| + 1$ .
3. при предположенията на предишната подточка докажете, че след изпълнението на **NewSlink**<sup>2</sup> функцията  $\text{slink} = \text{slink}_{w'}$ .

## 4 Конструиранието на преходите $\delta_{w'}$

**Задача 4.1.** Нека  $w \in \Sigma^*$ ,  $a \in \Sigma$  и  $w' = w \circ a$ . Нека  $u$  е дефинирано както в задача 3.2, а  $v \in Q_w \cup \{\text{slink}_{w'}(w')\}$  е произволно. Докажете, че ако  $a \neq b \in \Sigma$ , то:

1.  $\delta_{w'}(w', b)$  не е дефинирано.
2.  $\delta_{w'}(v, b) = \delta_w(v, b)$  за  $v \in Q_w$ .
3.  $\delta_{w'}(v, b) = \delta_w(\delta_w(u, a), b)$  ако  $v = \text{slink}_{w'}(w') \notin Q_w$ .

**Задача 4.2.** Нека  $w \in \Sigma^*$ ,  $a \in \Sigma$  и  $w' = w \circ a$ . Нека  $u$  е дефинирано както в задача 3.2, а  $v \in Q_w \cup \{\text{slink}_{w'}(w')\}$  е произволно. Докажете, че:

1.  $\delta_{w'}(v, a) = \delta_w(v, a)$  ако  $v \notin \text{Suff}(w)$ .
2.  $\delta_{w'}(v, a) = w'$ , ако  $v \in \text{Suff}(w) \cap Q_w$ ,  $|v| > |u|$ ,
3.  $\delta_{w'}(v, a) = \delta_{w'}(\delta_w(u, a), a)$ , ако  $v = \text{slink}_{w'}(w') \notin Q_w$ .

**Задача 4.3.** Разгледайте процедурата **InsertNextChar**, която се изпълнява с  $Q = Q_w$ ,  $\text{slink} = \text{slink}_w$  и  $\delta = \delta_w$ . Докажете, че ако се изпълни ред @11, то непосредствено след това:

1.  $Q = Q_{w'}$ , където  $w' = w \circ a$ ,
2.  $\text{slink} = \text{slink}_{w'}$ ,

<sup>1</sup>Може да се абстрахирате засега от ред @3.

<sup>2</sup>Може да се абстрахирате засега от редове @6 и @7.

3.  $\delta(v, b) = \delta_{w'}(v, b)$  за всички състояния  $v \in Q$  и  $b \in \Sigma$  с изключение може би на  $b = a$  и  $v \in \text{Suff}(w)$  с  $|v| \leq |u|$ .

**Задача 4.4.** Нека  $w \in \Sigma^*$ ,  $a \in \Sigma$  и  $w' = w \circ a$ . Нека  $u$  е дефинирано както в задача 3.2, а  $v \in \text{Suff}(w)$  с  $|v| \leq |u|$  е произволно. Тогава  $\delta_{w'}(v, a) = \begin{cases} \text{slink}_{w'}(w') & \text{ако } \delta_w(v, a) = \delta_w(u, a) \\ \delta_w(v, a), & \text{иначе.} \end{cases}$

**Задача 4.5.** Докажете, че ако  $Q = Q_w$ ,  $\text{slink} = \text{slink}_w$  и  $\delta = \delta_w$  за някоя дума  $w \in \Sigma^*$ , то след изпълнението на **InsertNextChar**  $Q = Q_{w \circ a}$ ,  $\text{slink} = \text{slink}_{w \circ a}$  и  $\delta = \delta_{w \circ a}$  като резултатът е  $w \circ a$ .

	<b>InsertNextChar</b> ( $Q, \text{slink}, \delta, w, a$ )
	@1 $w' \leftarrow w \circ a$
	@2 $Q \leftarrow Q \cup \{w'\}$
<b>Redirect</b> ( $Q, \text{slink}, \delta, u, s, a$ )	@3 $u \leftarrow \text{FindStem}(Q, \text{slink}, \delta, w, w', a)$
@1 $v \leftarrow \delta(u, a)$	@4 <b>if</b> $u = \text{NULL}$ <b>then</b>
@2 <b>while</b> $u$ <b>is defined and</b>	@5 $\text{slink}(w') \leftarrow \varepsilon$
$\delta(u, a) = v$ <b>do</b>	@6 <b>return</b> $w'$
@3 $\delta(u, a) \leftarrow s$	@7 $v \leftarrow \delta(u, a)$
@4 $u \leftarrow \text{slink}(u)$	@8 <b>if</b> $ v  =  u  + 1$ <b>then</b>
@5 <b>done</b>	@9 $\text{slink}(w') \leftarrow v$
	@10 <b>return</b> $w'$
	@11 $s \leftarrow \text{NewSlink}(Q, \text{slink}, \delta, u, w', a)$
	@12 <b>Redirect</b> ( $Q, \text{slink}, \delta, u, s, a$ )
	@13 <b>return</b> $w'$

## Литература

- [BBH<sup>+</sup>85] A. Blumer, J. Blumer, D. Haussler, A. Ehrenfeucht, M. T. Chen, and J. Seiferas. The smallest automation recognizing the subwords of a text. *Theoretical Computer Science*, 40:31 – 55, 1985. Eleventh International Colloquium on Automata, Languages and Programming.

## Упътвания към някои от задачите

**Упътване 4.1** (Упътване за задача 2.2). Използвайте задачи 1.2 и 1.4.

Тъй като  $u \equiv_{\text{Suff}(w)} v$ , но  $u \not\equiv_{\text{Suff}(w')} v$ , то една от думите  $u$  и  $v$  е суфикс на  $w'$ , а другата – не, защото техните  $\text{end-pos}_{w'}(\cdot)$  множества могат да се различават единствено по елемента  $|w'|$ . Ако  $|w'| \in \text{end-pos}_{w'}(v) \setminus \text{end-pos}_{w'}(u)$ , разгледайте два случая:

1.  $\text{end-pos}_{w'}(v) = \{|w'|\}$ . Тогава  $v \equiv_{\text{Suff}(w')} w'$  като обърнете внимание, че  $\text{end-pos}_{w'}(u) = \emptyset$ . Тази ситуация може да интерпретираме като  $u \notin \text{Inf}(w')$  и  $v$  се среща един единствен път в  $w'$  при това като суфикс.
2.  $|w'| \subsetneq \text{end-pos}_{w'}(v)$ . Тогава има позиция  $k \neq |w'|$ , за която  $k \in \text{end-pos}_{w'}(v)$ . Оттук  $k < |w'|$  и следователно  $v \neq_{w'} w'$  и  $v \in \text{Inf}(w)$ . Нека  $\overleftarrow{v} \equiv_{\text{Suff}(w')} v$  е най-дългият представител в класа на  $v$  относно  $\equiv_{\text{Suff}(w')}$ . Тогава  $\overleftarrow{v}$  завършва на позиция  $|w'|$  в  $w'$ ,

следователно е суфикс на  $w'$ . Аналогично, тъй като  $\overleftarrow{v}$  завършва и на позиция  $k$  в  $w$ . Тъй като  $u$  също завършва на позиция  $k$  в  $w$ , но не и на позиция  $|w'|$  в  $w'$ , то:

$$u = \alpha \circ b \circ \overleftarrow{v} \text{ и } w' = \beta \circ c \circ \overleftarrow{v}.$$

В  $w$  имаме, че  $\text{end-pos}_w(\overleftarrow{v}) = \text{end-pos}_w(v) = \text{end-pos}_w(u)$ . Оттук получаваме, че  $\text{end-pos}_w(\overleftarrow{v}) = \text{end-pos}_w(b \circ \overleftarrow{v})$ , но тогава  $c \circ \overleftarrow{v} \notin \text{Inf}(w)$ , откъдето наистина  $\overleftarrow{v} = \text{slink}_{w'}(w')$ .

*Упътване 4.2 (Упътване за задача 2.4).* Използвайте задача 2.2 и разсъжденията от нея.

*Упътване 4.3 (за задача 4.1).* Забележете, че ако  $b \neq a$  то  $\text{end-pos}_w(v \circ b) = \text{end-pos}_{w'}(v \circ b)$ . Сега използвайте задача 1.4

*Упътване 4.4 (за задача 4.2).* Отново използвайте задача 1.4.

*Упътване 4.5 (за задача 4.4).* Забележете, че ако  $v$  е както в условието и  $\delta_w(v, a) \neq \delta_w(u, a)$ , то позицията  $|w| + 1 = |w'|$  се добавя към всички елементи от класа на еквивалентност  $[v \circ a]_{\text{Suff}(w)}$ . Тогава той остава непроменен.

Относно тези  $v$ , за които  $\delta_w(v, a) = \delta_w(u, a)$ . За тях имаме, че  $v \circ a \equiv_{\text{Suff}(w)} u \circ a$  и тъй като  $v \circ a$  е суфикс и на  $w'$  както и  $u \circ a = \text{slink}_{w'}(w')$ , то  $v \circ a \equiv_{\text{Suff}(w')} u \circ a$ .